

HealthConnect Advanced Analytics & Decision Support Report

Validation et approfondissement de l'analyse des rendez-vous manqués

AnalystLab Africa Experience Lab — Track : Data Analytics, Semaine 6

HealthConnect Clinic — Integration, Advanced Development & Validation

Jeu de données : HealthConnect Appointment Dataset (5 000 rendez-vous, 18 variables)

Outils : Python (pandas, matplotlib) et Microsoft Power BI

Auteur : SOME Oho Prisca Gaëlle

1. Transition Semaine 5 → Semaine 6

Livrable principal S5 : notebook (préparation des données, EDA à 6 visualisations, 5 KPI, 5 insights, 5 recommandations) complété par un dashboard Power BI interactif (5 cartes KPI, 5 visuels, 3 filtres).

Résultat le plus important : taux de no-show global de 48,5% ; signal le plus fort identifié l'historique du patient (43,5% sans antécédent → 55,4% chez les récidivistes) ; effet rappel (51,4% sans vs 47,4% avec) ; effet délai (27,8% ≤7j → 60,5% >30j).

Problème/limite principaux découverts en S5 : l'incohérence entre les rendez-vous du dimanche présents dans les données et la Knowledge Base annonçant la clinique fermée ce jour ; la robustesse de l'imputation médiane sur la distance non encore vérifiée ; le rappel de la limite corrélation ≠ causalité.

Track pertinent pour la Semaine 6 : Data Science transmission de features validées et d'une définition de cible (No-Show, Cancelled exclus) pour leur modèle prédictif ; réception de leurs besoins en format et priorités de variables.

Objectif Semaine 6 : approfondir trois findings (interaction rappel × délai, effet Sunday, segments jamais explorés), valider les KPI de S5 (effectifs et sensibilité de l'imputation), améliorer le dashboard, et livrer un jeu de features à la Data Science.

2. Analyses approfondies

A. L'effet du rappel tient-il partout ? (Interaction rappel × délai)

Le taux de no-show reste plus élevé sans rappel qu'avec rappel dans les trois tranches de délai, et l'écart s'accroît avec le délai (-2,9 points ≤7j → -4,3 points >30j). Nuance importante : même rappelés, 59,3% des rendez-vous réservés à plus de 30 jours restent manqués. Verdict : le finding S5 est validé et raffiné le rappel seul ne suffit pas sur les réservations longues, d'où la recommandation d'un second rappel à mi-parcours.

B. Qui concentre les no-shows ? (Poids des récidivistes)

47,5% de l'ensemble des no-shows proviennent de patients déjà récidivistes (au moins un no-show antérieur). L'absentéisme n'est donc pas diffus : il est concentré sur un groupe identifiable et de taille gérable, ce qui renforce directement la recommandation d'un protocole de suivi prioritaire dès le premier no-show cibler ce seul groupe traite près de la moitié du problème.

C. Le dimanche : vrai signal ou effet de petit effectif ? (validation)

Le dimanche totalise 737 rendez-vous, un effectif comparable aux autres jours de la semaine son taux de no-show de 50,5% n'est donc pas un artefact statistique lié à un faible nombre d'observations. Ce volume, sur un jour que la Knowledge Base annonce pourtant fermer, confirme et renforce l'incohérence entre les données et la documentation officielle, déjà signalée en Semaine 5 : elle est escaladée au niveau du projet et transmise au track Generative AI.

D. Sensibilité de l'imputation de la distance (validation)

Le KPI distance recalculé uniquement sur les données originales (sans les 90 valeurs imputées par la médiane) donne des taux quasi identiques à ceux obtenus avec imputation. L'imputation ne distord donc pas le résultat : le KPI distance est confirmé robuste.

E. Nouvelles dimensions explorées (segments jamais analysés en S5)

Les patients de 65 ans et plus sont les moins absents (45,1%) ; les tranches 25-34 ans et 55-64 ans sont les plus absentes (50,7%). Par type de rendez-vous, le suivi (follow-up) enregistre le taux le plus élevé (51,2%) contre 46,6% pour une consultation générale. Ces effets, de l'ordre de 4 à 5 points, restent modestes : ce sont des lectures secondaires, utiles comme variables complémentaires pour la modélisation, mais pas des leviers d'action prioritaires.

3. Hiérarchie des effets (impact business)

Délai de réservation (~33 points d'écart) >> récidive (~12 points) > distance (~8 points, effet robuste) > âge ≈ type de rendez-vous ≈ rappel ≈ jour (~4-5 points) > genre (~0 point).

Cette hiérarchisation oriente clairement les priorités d'action de la clinique : délai de réservation, récidive et rappel sont les trois leviers à traiter en premier, les autres facteurs jouant un rôle secondaire.

4. Verdict des KPI de la Semaine 5

KPI Semaine 5	Verdict	Preuve Semaine 6
Taux global (48,5%)	Confirmé	Stable dans l'ensemble des coupes analysées.
Rappel (51,4% vs 47,4%)	Validé et raffiné	Effet confirmé dans toutes les tranches de délai, mais insuffisant seul au-delà de 30 jours.
Jour/créneau (dimanche 50,5%)	Validé mais nuancé	Effectif solide (n=737) ; effet réel mais modeste ; incohérence avec la Knowledge Base à documenter.
Distance (46,5% → 54,1%)	Robuste	Résultat quasi identique en analyse de sensibilité sans imputation.
Récidive (43,5% → 55,4%)	Renforcé	47,5% de l'ensemble des no-shows proviennent de récidivistes.

5. KPI raffinés (Semaine 6)

1. Écart de no-show avec/sans rappel par tranche de délai remplace le KPI global rappel de S5, plus actionnable car il montre où le rappel seul ne suffit plus.
2. Part des no-shows attribuables aux récidivistes = 47,5% quantifie précisément l'impact d'un protocole de suivi ciblé sur ce seul groupe.
3. Règle de méthode adoptée : ne conclure sur un segment qu'à partir d'un effectif minimal de 100 rendez-vous, afin d'éviter de sur-interpréter un effet basé sur un petit échantillon.

6. Mise à jour du dashboard Power BI

Une seconde page (« Semaine 6 : Validations & Intégrations ») a été ajoutée au dashboard existant, avec 5 cartes KPI (taux global, sans rappel, avec rappel, part de récidivistes parmi les no-shows, taux à plus de 30 jours malgré rappel) et 4 nouveaux visuels : effet du rappel croisé par tranche de délai, taux de no-show par type de rendez-vous, tableau détaillé d'absentéisme par jour avec volumes, et la répartition des no-shows entre récidivistes et non-récidivistes.

7. Recommandations

1. Rappel systématique, complété par un second rappel à mi-parcours pour toute réservation à plus de 30 jours l'effet du rappel seul s'érode nettement sur les délais longs.
2. Double confirmation des rendez-vous du dimanche et du vendredi soir, les deux créneaux à plus fort risque validé.
3. Suivi prioritaire (confirmation téléphonique) dès le premier no-show d'un patient ce seul groupe concentre 47,5% de l'ensemble des absences.
4. Accompagnement renforcé des patients à plus de 15 km (rappel supplémentaire, option de téléconsultation) effet confirmé robuste après analyse de sensibilité.
5. Gouvernance des données : documenter formellement l'incohérence entre les rendez-vous du dimanche et la Knowledge Base avant toute décision opérationnelle fondée sur ce jour.

8. Limites, risques et dépendances — mise à jour

Toujours valables

- Données fictives : les schémas observés devront être validés sur données réelles.
- Corrélation $\neq$ causalité : le lien rappel/présence reste une association statistique.
- Périmètres adultes uniquement (18-80 ans) : non généralisable à une patientèle pédiatrique.
- Cancelled exclu du calcul du taux de no-show : choix de périmètre maintenu.

Résolues cette semaine

- Robustesse de l'imputation de la distance : vérifiée par analyse de sensibilité, écart négligeable.
- Fiabilité du signal « dimanche » : confirmée par un effectif suffisant (n=737), ce n'est pas un artefact statistique.

Nouveau problème découvert

- Le regroupement en tranches (délai, distance) fait perdre en finesse ce que l'analyse par variable brute conserverait ; à rouvrir si une décision opérationnelle exige plus de précision qu'une tranche agrégée.

9. Contribution et collaboration cross-track

Collaboration 1 — Data Analytics → Data Science

Dépendance : un modèle entraîné sur une cible ou des features mal définies hériterait des erreurs de périmètre de l'analyse. Échangé : la définition de la cible (No-Show, Cancelled exclus), le signal `previous_no_shows`, les tranches délai/distance validées. Activité réalisée : export du fichier `HealthConnect_features_for_DS.csv` (19 colonnes incluant les variables dérivées `no_show`, `recidiviste`, `long_lead`, `lead_band`, `dist_band`, `ratio_no_shows_passes`) accompagné d'une note d'analyse. Résultat : cible et variables candidates alignées avant modélisation, réduisant le risque de refaire ce travail en double.

Collaboration 2 — Data Analytics → Generative AI

Dépendance : l'assistant conversationnel ne doit pas communiquer d'horaires inexacts aux patients. Échangé : le constat validé (effectif n=737) que des rendez-vous du dimanche existent dans les données alors que la Knowledge Base annonce la clinique fermée ce jour. Résultat :

l'ambiguïté est signalée avant la rédaction des réponses de l'assistant sur les horaires d'ouverture.

Note : l'ensemble des chiffres provient du HealthConnect Appointment Dataset (5 000 rendez-vous), tel qu'analysé dans le notebook Python joint et restitué dans le dashboard Power BI associé (page « Semaine 6 »).