

Week 4 Project Summary

HealthConnect Clinic — Improving Patient Appointment Attendance Using Data and AI

AnalystLab Africa Experience Lab — Track : Data Analytics | Auteur : SOME Oho Prisca Gaëlle

1. Problème adressé par le track Data Analytics

HealthConnect Clinic, centre de santé fictif fonctionnant sur rendez-vous, fait face à un taux élevé de rendez-vous manqués (no-show), qui gaspille des créneaux et dégrade l'efficacité opérationnelle. Ma contribution, en tant que Data Analyst, est d'explorer les données de rendez-vous afin d'identifier les facteurs associés au no-show et de poser les bases d'une analyse quantitative exploitable par la direction pour réduire ce phénomène.

2. Ressources utilisées

HealthConnect_Appointment_Data.csv (5 000 rendez-vous, 18 colonnes) et le dictionnaire de données associé, consulté pour valider le sens et le format attendu de chaque variable avant l'exploration. Une ligne du dataset correspond à un rendez-vous ; un même patient peut apparaître sur plusieurs lignes. La variable cible est appointment_outcome (Attended / No-Show / Cancelled).

3. Observations clés de la Semaine 4

- Qualité des données : aucun doublon détecté. Trois colonnes comportent des valeurs manquantes : reminder_channel (1 366, manquant logique cohérent avec les 1 366 rendez-vous sans rappel envoyé), distance_to_clinic_km (90) et waiting_time_minutes (60), ces deux dernières correspondant à de vrais manquants signalés par le dictionnaire de données.
- Format des dates : booking_date et appointment_date sont stockées en texte (mm/jj/aaaa) et devront être converties avec pd.to_datetime avant toute analyse temporelle.
- Répartition de la variable cible : 2 423 No-Show, 2 314 Attended, 263 Cancelled. Le taux de no-show retenu est de 48,5% (calculé sur l'ensemble des rendez-vous réservés), car il reflète la perte réelle subie par la clinique une annulation libère le créneau à l'avance, contrairement à un no-show.
- Signal le plus fort identifié : le nombre de no-show passés (previous_no_shows). Le taux de no-show progresse de 43,5% pour les patients sans antécédent jusqu'à 100% pour ceux ayant déjà manqué 5 rendez-vous une relation quasi monotone.
- Effet protecteur du rappel : le taux de no-show est plus élevé sans rappel envoyé (51,4%) qu'avec rappel (47,4%).
- Effet du délai de réservation : les patients en no-show réservent en moyenne 34,5 jours à l'avance, contre 24,5 jours pour les patients présents un délai long semble favoriser l'oubli.
- Effets secondaires observés : le samedi et le créneau du soir affichent les taux de no-show les plus élevés ; les patients en no-show habitent en moyenne un peu plus loin (10,5 km contre 9,7 km).
- Hypothèse testée et écartée : le temps d'attente en clinique (waiting_time_minutes) ne présente aucune différence notable entre les patients présents et absents (24,2 contre 24,3 minutes) l'attente n'explique donc pas l'absentéisme.

4. Approche proposée

Démarche en quatre phases pour la Semaine 5 : (1) nettoyage et préparation conversion des dates, décision sur le traitement des valeurs manquantes de distance et de temps d'attente, traitement séparé des rendez-vous annulés ; (2) calcul des 5 KPI identifiés (écart de no-show avec/sans rappel, taux par créneau, par tranche de distance, par délai de réservation, taux de récurrence) ; (3) visualisation des résultats sous Power BI ou matplotlib ; (4) traduction des constats en recommandations opérationnelles pour la clinique (ciblage des rappels, ajustement des plannings, suivi prioritaire des patients récidivistes).

5. Considérations clés (hypothèses, limites, risques)

- Données fictives : les schémas observés peuvent ne pas refléter le comportement réel d'une patientèle, les conclusions devront être validées sur données réelles.
- Choix de périmètre documenté : les rendez-vous annulés (Cancelled) sont exclus du calcul principal du taux de no-show, un choix assumé et modifiable.
- Corrélation $\neq$ causalité : le lien observé entre rappel et présence est une association statistique, pas une preuve d'effet direct.
- Périmètres adultes uniquement (18-80 ans selon le dictionnaire) : les résultats ne sont pas généralisables à une patientèle pédiatrique.

6. Focus proposé pour la Semaine 5

Prioriser le calcul et la visualisation des KPI liés aux deux signaux les plus forts identifiés cette semaine l'historique de no-show (previous_no_shows) et l'effet du rappel (reminder_sent) avant d'approfondir les facteurs secondaires (créneau, distance, délai de réservation), afin de proposer rapidement à la clinique des leviers d'action prioritaires et mesurables.